# 6. Corpora as Digital Tools

Photo by Susan Q Yin on Unsplash

# 第 6 章　デジタルツールとしてのコーパス：コーパス研究の基礎と検索

## 6.1　人文学研究でコーパスを用いる意義

コーパス（大規模言語データベース）を人文学研究に活用することには、いくつか重要な意義があります。第一に、研究の再現性を高めることができます。従来の人文学では、研究者ごとの解釈や直感に頼る部分が大きく、同じ資料から異なる解釈が生まれることもしばしばでした。しかしコーパスを用いることで、誰もが同じデータにアクセスし、同じ検索手順を踏めば同様の結果を得られるため、研究結果の検証や追試が容易になります。第二に、確証バイアスの回避につながります。確証バイアスとは、自分の仮説に都合の良い事例ばかりを集めてしまう傾向のことです。コーパス上で網羅的にデータを観察すれば、恣意的に例を選ぶ余地が減り、仮説に合致する例だけでなく反証例も含めて客観的に検討できます。第三に、解釈の根拠を可視化できる点も重要です。コーパスから得られた結果（例えばある語の使用頻度や用例の一覧）は、解釈を裏付ける明確なエビデンスとなります。議論の際にも「この語はコーパス中で X 回出現し、その大半が Y という文脈で使われています」のように具体的なデータを示せるため、従来の曖昧な主観的判断に比べて説得力が増します。

このようにコーパスは、人文学を単に「データ化」する以上の意味を持っています。それは人文学を「解釈の学」から「実証の学」へと開き、データによる客観的観察と人間的な解釈とを統合する試みでもあります。コーパスに基づく分析によって、個々の解釈に客観的根拠を与えつつ、人文学固有の洞察と組み合わせることが可能になるのです。21 世紀の人文学研究において、コーパスは再現性ある観察にもとづく新たな知の創出を支える基盤となり得るでしょう。

## 6.2　コーパスの定義と基本的特徴

まずコーパスという用語の定義を確認しましょう。コーパス（Corpus）とは、現実に使用された大量の言語データを電子的に集積・構造化したデータベースのことです。テキストデータ（文章や会話の書き起こし）がコンピュータで検索・分析できる形で蓄えられており、日本語では「言語コーパス」などと呼ぶこともあります。典型的には数百万語から数億語規模にも及ぶ自然言語の用例を含み、言語学の研究、辞書や文法書の編纂、言語教育などで重要なリソースとして活用されています。

コーパスには次のような基本的特徴があります。

1. **大規模な言語データベースであること：** コーパスは非常に大量の言語使用例を含みます。例えば代表的な英語コーパスである **BNC**（British National Corpus）は約 1 億語の現代英語テキ

ストから成り立っています。規模が大きいことで、ある単語の出現頻度を統計的に調べたり、珍しい表現の用例を見つけたりすることが可能になります。

2. **自然言語の実例を集めていること:** コーパスに収録されるデータは、新聞記事、会話の記録、小説、ウェブテキストなど、実際に使われた言語の実例です。研究者が頭で考えた例文ではなく現実の用例に基づくため、分析に客観性と現実性を与えます。「話し言葉ではこういう言い方はしないのではないか？」といった疑問も、実際の使用例を調べることで確認できます。
3. **電子化され検索可能であること:** コーパスはコンピュータ上で利用でき、検索ソフトやプログラムを使って容易に分析できます。例えば、語の出現頻度を数えたり、ある語がどのような文脈で使われるかを調べたりといったことが自動化できます。近年はウェブ上で公開されているコーパスも多く、インターネットに接続できればブラウザ上で利用できるものもあります。専用ツールを使うことで、複雑な検索（後述の CQL など）や統計的分析も可能です。
4. **注釈（アノテーション）が付与されていること:** 多くのコーパスには各単語の品詞や文法構造などの情報が付与されています。例えば BNC や日本語の **BCCWJ**（現代日本語書き言葉均衡コーパス）では、収録テキスト中のすべての単語に品詞タグが付いています。その結果、「名詞だけを検索する」「動詞＋目的語のパターンを抽出する」といった高度な検索が可能になります。品詞や構文情報付きのコーパス（アノテーション付きコーパス）を利用すれば、特定の言語現象を効率よく抽出・分析できるわけです。
5. **研究・教育への幅広い応用:** コーパスは言語研究の基盤資料であり、辞書や文法書の編纂、言語学の仮説検証などに広く使われています。さらに語学教育の分野でも、教材開発や学習者の誤用分析、コーパスに基づくデータ駆動型学習（Data-Driven Learning; DDL）などに活用されています。たとえば学習者が実際に書いた作文コーパスから共通の誤りを分析し指導に役立てる、といった実践も行われています。

以上のように、コーパスは単にテキストを集めただけのものではなく、検索や解析を通じて言語現象を客観的に捉えるためのデジタル基盤です。人文学系の研究者にとって、コーパスを使いこなすことは現代の研究において大きな武器になるでしょう。

## 6.3 コーパスの種類

コーパスには様々な種類があり、構築方法や用途によって分類できます。主な種類とその特徴・用途を以下に整理します。

- **均衡コーパス (Balanced Corpus):** あらかじめコーパスの規模や収集範囲を定め、言語全体を代表するように多様なジャンルからバランスよくデータを集めて構築されたコーパスです。いわば言語のスナップショットであり、特定の時期・領域の言語使用を偏りなく反映することを目指します。典型例として英国英語の BNC（約 1 億語規模で書き言葉 90%、話し言葉 10% の比率で構成）や、日本語の BCCWJ（書籍・雑誌・ウェブ記事・ブログ等からサンプリングされた 1 億語規模のコーパス） があります。均衡コーパスは一般言語の全体像をつかむのに適しており、言語変化の追跡や方言比較など、コーパス間の比較研究にも基準として用いられ

ます。ただし構築には綿密な計画が必要で、完成後に新語や言語変化が起きても内容が固定されたままである点には注意が必要です。

- **モニターコーパス (Monitor Corpus):** 継続的にデータが追加・更新されていく動的なコーパスです。言語の変化を逐次「監視（モニター）」する目的で設計されており、新語の出現状況や語の使用頻度の変遷を追跡するのに向いています。例えばアメリカ英語の大型コーパスである COCA (Corpus of Contemporary American English) や、かつて存在した Bank of English（1980 年代から更新され約 5 億語規模に達したコーパス）などがモニターコーパスに該当します。モニターコーパスは長期間の言語変化を分析できる反面、データが次々と追加され内容が流動的なため、同じ条件での再現性や全体のバランス維持が課題となり得ます。
- **アノテーション付きコーパス:** 原文テキストに品詞や構文構造、意味情報などの注釈（アノテーション）が付与されたコーパスです。単にテキストを蓄えただけでなく、各単語に品詞ラベルを付けたり、文構造をツリー形式で付記した「ツリーバンク」や、照応関係・意味役割を注記したものなど様々な種類があります。注釈付きコーパスを用いることで、例えば「名詞句に限定して検索する」「主語と目的語の関係を持つ文を抽出する」など高度な分析が可能です。代表例として、英語の **Penn Treebank**（ペンシルベニア大学ツリーバンク；英語の構文木コーパス）や、日本語では前述の BCCWJ（形態素・品詞情報付きで提供）や日本語話し言葉コーパスの CSJ（音声と形態情報付きの話し言葉コーパス）などが挙げられます。こうしたコーパスは自然言語処理の機械学習用データとしても不可欠であり、また精密な言語研究（構文パターンの頻度分析など）にも活用されています。
- **パラレルコーパス (Parallel Corpus):** 二つ以上の言語で内容が対応しているテキストを対にして収録したコーパスです。簡単に言えば翻訳テキストの原文と訳文を揃えたものです。多言語の翻訳研究や機械翻訳の開発にしばしば用いられ、例えば国際連合の公用語文書を集めた多言語コーパスや、欧州議会の議事録を集めた **Europarl** コーパスは典型的なパラレルコーパスです。原文と翻訳文が対応していることで、「この日本語の表現は英語ではどう訳されるか」といった対比調査や、翻訳時に追加・省略された情報の分析などが容易にできます。パラレルコーパスは対訳辞書の編纂や異文化間の言語表現比較にも有用です。
- **専門分野コーパス (ドメインコーパス):** 特定の専門領域・ジャンルに特化してテキストを集めたコーパスです。例えば医学論文だけを集めた医学英語コーパス、法律文書のコーパス、ある作家の全作品コーパス、あるいは石油工学の専門用語に特化したコーパスなどが考えられます。対象を絞ることで、その分野特有の用語や言い回し、スタイルの特徴を詳細に分析できます。専門分野コーパスは専門用語辞典の作成や、ジャンル別の文体研究に役立ちます。また人文学の研究者が自前でコーパスを構築する場合も、自分の研究対象に合わせたドメインコーパスを作るケースが多いでしょう。
- **学習者コーパス (Learner Corpus):** 第二言語・外国語としてその言語を学ぶ学習者が実際に書いた作文や発話を収集したコーパスです。非母語話者特有の誤用や中間言語の特徴をデータとして記録している点に特徴があり、応用言語学や言語教育の研究で重宝されます。有名な例としてはケンブリッジ大学による **Cambridge Learner Corpus**（世界中の英語学習者の試験

作文を集めたコーパス）があります。学習者コーパスを分析することで、学習者に共通する間違いを発見したり、ある言語項目の習得の難しさを測ったりできます。日本語でも「日本語学習者作文コーパス」などが構築され、学習者の誤用傾向を教材開発に生かす研究が行われていました（現在は公開終了）。

- **ウェブコーパス:** インターネット上の大量のウェブページからテキストを収集して構築されたコーパスです。現在ではウェブは最大級の言語資料の宝庫であり、専用のクローラプログラムで何十億もの単語を含むテキストを収集することが可能です。ウェブコーパスは圧倒的なデータ量と多様性を確保できるのが利点で、珍しい表現例や最新の流行語・専門語も見つけやすいという魅力があります。一方で課題も多く、まず収集したテキストの代表性を担保するのが難しい点が挙げられます。ウェブ上のテキストは玉石混淆でジャンル分類が困難であり、一つのページに複数の文体が混在することもあります。そのため均衡コーパスのように厳密にバランスを取ることが難しいのです。次に品質管理の問題があります。タイポや非標準的な表記、広告・スパム的内容などノイズが多く含まれがちで、これらをフィルタしてクリーンなデータに整える手間がかかります。さらにウェブには事実誤認の情報や機械翻訳文、過激な表現も含まれるため、分析結果の解釈には慎重さが必要です。最後に法的・倫理的課題として、ウェブからの大量収集では著作権やプライバシーへの配慮も欠かせません。こうした課題はありますが、ウェブコーパスは規模と新鮮さという点で魅力的なリソースであり、適切なフィルタリングや技術の進歩によって徐々に克服されつつあります。

以上、主要なコーパスの種類を見てきました。これらの分類は時に重なり合うこともあります（例えばパラレルコーパスで品詞タグが付いていれば「注釈付きコーパス」にも該当しますし、学習者コーパスは特定属性に特化した専門コーパスと見ることもできます）。大切なのは、自身の研究目的に合ったコーパスを選ぶことです。言語の現在の全体像を知りたいなら均衡コーパス、新語の出現を追跡したいならモニターコーパス、特定分野の表現を調べたいなら専門分野コーパス、といった具合に使い分けると良いでしょう。

## 6.4 研究目的に応じたコーパス選択のポイント

実際にコーパスを選んだり自作したりする際には、いくつか考慮すべきポイントがあります。研究の目的に照らして最適なコーパスを選ぶために、次の点に注意してください。

- **代表性:** コーパスが自分の研究したい言語現象にとって充分に代表的かを考えましょう。例えば現代一般英語の語法を研究したいのに古典英語コーパスでは不適切ですし、ある作家の文体を分析したいならその作家のテキストを含むコーパス、あるいは自前で作品コーパスを構築する必要があります。コーパスの構成要素（ジャンルや話者属性など）が自分の研究の対象を偏りなくカバーしているかを確認することが重要です。
- **ジャンル・文体のバランス:** 上記の代表性と関連しますが、コーパス内のジャンル分布にも注意します。特に均衡コーパス以外では、何らかの偏りがあるものです。例えば Web 由来のコーパスはブログや会話調の文章が多めになる、といった傾向があり得ます。自分の分析した

いジャンルが十分な量含まれているか、あるいは不要なジャンルが混ざり過ぎていないかを検討しましょう。必要に応じてコーパス内でジャンルフィルタをかけて分析することも有効です。

- **データの品質とノイズ:** コーパスのテキストデータがどの程度クリーンかも重要です。人手で校正されたコーパスであれば誤字脱字は少ないですが、ウェブコーパスのように自動収集されたものには誤記や異体表記、文字化け、不適切な内容（スパム等）が混入しやすいです。ノイズの多いコーパスを使うと分析結果にも影響が出るため、可能ならテキストクリーニングがなされているか、注釈精度が高いか、といった点も確認すると良いでしょう。
- **著作権・プライバシー:** 特に自分で新たにコーパスを構築する場合は、収集するテキストの権利処理に気を配る必要があります。著作権で保護された文章を無断で大量に収集・公開することは法律上問題がありますし、日記や SNS 投稿などには個人情報が含まれる可能性もあります。研究用途であっても、その範囲が非公開での分析に留まるのか、結果を論文等で公表するのかによって対処も変わります。既存の公開コーパスを利用する場合でも、その利用許諾範囲（商用利用の可否や再配布の禁止等）を守ることが大切です。

以上の点を踏まえ、研究目的に最も適したコーパスを選択・構築することで、分析結果の信頼性と有用性が高まります。最適なコーパスを選ぶこと自体が研究の成否を左右すると言っても過言ではありません。

## 6.5 コーパス研究のアプローチ：Corpus-based と Corpus-driven

コーパスを用いた研究スタイルには、大きく分けて二つのアプローチが存在します。一つは事前に仮説を立ててコーパスで検証する**コーパス検証型アプローチ**（hypothesis testing approach、あるいは corpus-based アプローチ）で、もう一つは明確な仮説を持たずコーパスからパターンを発見する**コーパス駆動型アプローチ**（data-driven approach、あるいは corpus-driven アプローチ）です。それぞれ研究の進め方や得られる知見の性質が異なります。

### コーパス検証型アプローチ（Corpus-based アプローチ）

コーパス検証型は、あらかじめ設定した理論や仮説をコーパスデータによって検証する手法です。研究者は分析前に「〇〇という表現は話し言葉で多用されるはずだ」「英語の受動態は書き言葉で頻出するだろう」といった仮説や問いを立て、それに基づきコーパス検索と結果分析を行います。コーパスは実証的な裏付けを与える役割を果たし、仮説が正しいかどうかを統計的に確認したり、例証を集めたりするために用いられます。例えば「受動態の頻度が書き言葉と話し言葉でどう異なるか」を確かめる際に、それぞれのジャンルのコーパスから受動文の頻度を算出して比較検討するといった研究が考えられます。

このアプローチのメリットは、明確な問いに答える形で分析を進めるため結果の解釈がしやすく、エビデンスが直接仮説の支持・反証に結びつく点です。研究の焦点が定まっている分、必要なデータだけを効率よく抽出でき、得られた結果も仮説との対応で整理しやすい傾向があります。一

方デメリットとしては、仮説にない現象は見落としがちになるという点があります。最初に立てた仮説に沿ってデータを見るため、コーパス中に潜む意外なパターンに気付きにくく、分析の射程が限定される恐れがあります。また、そもそもの仮説設定が不適切だと、有益な結果が得られないまま終わってしまうリスクもあります。

## コーパス駆動型アプローチ（Corpus-driven アプローチ）

コーパス駆動型は、明確な仮説を最初から持たず、コーパスデータそのものの中からパターンや法則を見出そうとする手法です。既存の理論にとらわれず大量のデータを観察し、そこから知見を導くという「データ主導（ボトムアップ）」のアプローチになります。いわばコーパスに「何が起きているのか教えてもらう」スタンスで、頻出する語の共起パターンや統計解析手法を駆使し、後から仮説を構築していきます。例えば大規模コーパスを眺めているうちに「ある形容詞 X は特定の名詞 Y と非常に高頻度で共起している」ことに気づいたとします。その発見を受けて「X Y という組み合わせは一種の慣用表現ではないか」という仮説を後付けで立て、さらに検証するといった進め方です。

このアプローチのメリットは、予期しないパターンの発見につながりやすい点です。網羅的にデータを見ることで新しい言語事実や規則性を発掘でき、理論そのものの刷新につながることもあります。特に語彙研究やコロケーション（連語）研究では、コーパス駆動的な探索から得られた知見が数多く報告されています。また辞書編纂の分野でも、語の用法や意味のバリエーションをデータから抽出する際にデータ駆動型の手法が有効です。一方でデメリットは、分析範囲が広大になり焦点が絞りにくい点です。膨大なパターンの中から意味のあるものを取捨選択して理論化するには熟練を要し、仮説をまとめるまでに時間がかかることもあります。また、データ上の表面的なパターンに飛びついてしまうと見当違いの解釈をしてしまうリスクもあります。つまり、コーパス駆動型ではノイズの多いデータから有意味な信号を読み解く力が求められるわけです。

## アプローチの比較と統合

以上の二つのアプローチにはそれぞれ利点と欠点があり、相補的な関係にあります。コーパス検証型は演繹的（トップダウン）であり、理論の検証に向いている一方、コーパス駆動型は帰納的（ボトムアップ）で新知見の発見に優れています。前者は焦点が明確で再現性の高い分析が可能ですが、発想が仮説に依存するため見逃しも起こりえます。後者は網羅性が高く意外な発見につながりますが、ノイズとの戦いになりやすく効率が課題となります。実際の研究では、両者を組み合わせることで互いの欠点を補うことが多いです 。例えば、初めにコーパス駆動的にデータを探索して興味深いパターンを発見し、その後コーパス検証型の手法で追加データを用いて仮説を検証するといった手順です。このようにすれば新発見とその検証を一連の流れで行うことができます。また初心者のうちは、まずは検証型のように明確な問いを立ててコーパス分析を始めてみるのが取り組みやすいでしょう。慣れてきたら徐々にデータ駆動型の探索的分析にも挑戦してみることで、コーパスから得られる知見の幅が一層広がるはずです。

## 6.6　コーパス検索実習：Sketch Engine を利用した分析

以上でコーパスの基礎知識と理論的背景を概観しました。ここからは実際にコーパスを検索・分析する手順を学びましょう。実習には、世界的に広く使われているコーパス検索ツールである **Sketch Engine**[1)]を中心に扱います。適宜、日本語コーパス向けのツールである国立国語研究所の「**中納言**[2)]」についても触れます。読者が自身でコーパス検索を再現できるよう、アカウント登録から基本的な検索方法、そして簡単な分析例まで順を追って説明します。

### Sketch Engine とは何か

**Sketch Engine**（スケッチエンジン）は、チェコの Lexical Computing 社が開発した強力なオンラインコーパス検索・分析ツールです。世界各国の言語コーパス（100 以上の言語、500 以上のコーパス）を収録しており、研究用途から商用まで幅広く利用されています。例えば英語の BNC や米語の COCA、日本語のコーパスとしてはウェブから収集した日本語ウェブコーパスなども含まれています。特徴的な機能として、Word Sketch と呼ばれるコロケーションの自動要約機能があり、ある単語の用法を「主語になる名詞一覧」「目的語になる名詞一覧」「修飾する形容詞一覧」など文法関係ごとにまとめて表示できます。このように SketchEngine はコーパスから語彙の特徴を引き出すのに優れたツールで、本章の実習でも中心的に用います。

なお、SketchEngine を利用するには基本的にユーザ登録が必要です（学術研究者や学生向けに一定期間の無償トライアル登録が提供されています）。以下ではウェブブラウザ上で Sketch Engine に登録・ログインし、公開コーパスを使って検索・分析する手順を説明します。

### 中納言（NINJAL 中納言）の紹介

日本語のコーパスを使いたい場合には、国立国語研究所が提供する「**中納言**」というウェブアプリケーションも有力な選択肢です 。 中納言は主に同研究所が構築した日本語コーパス（現代日本語書き言葉均衡コーパス=BCCWJ や日本語話し言葉コーパス=CSJ、日本語歴史コーパス=CHJ など）を検索するためのツールです。形態素解析済みのデータに対して、高度な検索（品詞や活用形を指定した検索など）が可能で、日本語研究者にとって貴重な環境です。中納言の利用には利用申請と登録（利用許諾契約）が必要ですが、簡易版の「**少納言**」であれば申請不要で基本的な検索を試すことができます。本章では詳細な操作説明は省きますが、日本語でコーパス検索を行う際には中納言もぜひ活用を検討してください。次節からは英語コーパスを例に、Sketch Engine での検索実習を進めます。

---

1）`https://www.sketchengine.eu/`
2）`https://chunagon.ninjal.ac.jp/`

## Sketch Engine の利用準備（アカウント登録とログイン）

まずは SketchEngine を使えるように準備を行います。ウェブブラウザで SketchEngine の公式サイトにアクセスし、新規ユーザ登録を行ってください。登録画面では名前・所属・メールアドレス等の入力が求められます。学術目的であれば「Academic」プランのトライアルを選択すると良いでしょう（学生であることを明記するとスムーズです）。登録を送信すると確認メールが届くので、記載されたリンクをクリックしてアカウントを有効化します。続いてサイトにログインします。

ログイン後、SketchEngine のダッシュボード画面が表示されます。ここから分析に使うコーパスを選択しましょう。画面上部のメニューから「Corpora（コーパス）」を選ぶと、利用可能なコーパスの一覧が表示されます。言語やコーパス名でフィルタ検索もできます。今回は例としてイギリス英語の均衡コーパスである BNC (British National Corpus) を使いたいので、「British National Corpus」を選択します。[3] コーパスを選ぶと、そのコーパスに含まれる語彙数や概要が画面に表示されます。

以上で検索の準備が整いました。次に、実際の検索方法と基本機能について見ていきましょう。

## 基本的な検索方法（フリーワード検索と CQL）

Sketch Engine では、大きく分けて二通りの検索方法があります。一つはキーワードをそのまま入力して検索する簡易な方法（フリーワード検索）、もう一つは CQL（Corpus Query Language）と呼ばれるクエリ言語を用いて高度な条件を指定する方法です。

まずフリーワード検索から説明します。コーパスを選択した状態で画面上部の検索バーに調べたい単語やフレーズを入力し、Enter キーを押すだけで検索が実行されます。例えば BNC を選択した状態で `understand` と入力してみましょう。すると `understand` という文字列を含む用例がコーパス全体から検索され、結果が一覧表示されます。この簡易検索では部分一致検索（`understood` なども含む）にはならず、基本的には入力した形そのものに一致するもののみがヒットします。大文字小文字は区別されないので `Understand` でも結果は同じです。

次に CQL による検索です。より正確な検索や複雑な条件指定を行いたい場合、検索バーに特定の書式でクエリを書くことで高度な検索が可能です。CQL では検索したい語や品詞を `[ ]` で囲んで指定します。例えば「`[lemma="understand"]`」と入力すると、見出し語が *understand* である単語、すなわち *understand* の任意の活用形（*understands, understood, understanding* など）をまとめて検索できます。[4] また「`[word="understand"] [tag="NN.*"]`」のようにスペースで区切って連続した条件を書くと、「`understand` という単語に続いて名詞 (`NN`) が現れるパターン」を検索できます。CQL では正規表現や論理演算子も使えるため、「5 文字以上の名詞」や「同一文中で近距離に出現する 2 語」など複雑な検索も表現できます。最初は戸惑うかもしれませんが、Sketch Engine のヘルプには豊富なクエリ例が載っているので、少しずつ試してみると良いでしょう。

---

3） SketchEngine 内では BNC は “BNC (British National Corpus)’’ 等の名称でリストされています。

4） lemma=見出し語（原形）を指定するオプション。他に `word="…"`で字形そのまま、`tag="…"`で品詞タグ指定などが可能です。

## 基本機能：KWIC 表示・頻度分析・共起分析

検索結果の見方と、Sketch Engine の基本的な分析機能について説明します。

- **KWIC 表示（コンコーダンス）：** 検索を実行すると、デフォルトでは結果は KWIC 形式で表示されます。KWIC とは "Key Word in Context" の略で、検索語を中心に前後の文脈（コンテクスト）を数語ずつ表示したものです。例えば `understand` を検索した場合、「… understand …」のように該当語が中央に位置し、その左右に周囲の単語が表示されます。これによって、`understand` がどのような文脈で使われているかを直感的に把握できます。結果画面では各行がコーパス中の異なる用例を表し、行頭には文中の位置情報や出典テキストの ID などが併記されます。KWIC 表示をスクロールして眺めるだけでも、その語の典型的な使われ方（例えば頻出するフレーズや文型）を掴むことができます。
- **頻度分析:** 検索語の出現頻度は結果画面上部に表示されます。SketchEngine ではヒット件数とともに、コーパス全体における百万語あたり頻度（per million words; pmw）も表示されることがあります。例えば仮に BNC 中で `understand` が 2000 件ヒットした場合、BNC サイズが約 1 億語なので百万語あたり頻度は 20 回前後という計算になります（実際の値はもう少し多いでしょう）。頻度情報は、語がどれほど一般的かを示す指標であり、異なる語を比較したりジャンル間で出現率を比べたりする際に有用です。また SketchEngine には頻度表（Frequency List）機能もあり、コーパス中で最も頻出する単語を列挙したり、特定の条件下での頻度順位を調べたりできます。例えば「`understand` に直前に置かれる単語の頻度リスト」を作成すれば、「don't（否定形の *not*）」「can't（助動詞の否定）」「I（主語）」などが上位に来る、といったことが分かるでしょう。このように頻度分析によって語の使用傾向を定量的に捉えることができます。
- **共起（コロケーション）分析:** コーパス研究では、ある語と一緒によく現れる語（共起語, collocate）を調べることも重要です。Sketch Engine で `understand` を検索した結果画面には「Collocations（コロケーション）」タブや「Word Sketch」タブがあります。Collocations 機能では、検索語の左右一定範囲内に出現する単語で統計的に有意に頻度の高いものがリストアップされます。例えば `understand` の場合、左側によく現れる語として主語になりやすい *I*（I understand …）、否定を表す *not*（don't understand の形で）、助動詞の *can*（can/can't understand）などが上位に来るでしょう。また右側では接続詞 *that*（understand that …）や疑問詞 *why, how*（understand why/how …）などが頻出するはずです。さらに「Word Sketch」機能を使うと、`understand` を中心とした文法関係ごとの共起一覧が得られます。例えば「オブジェクト（目的語）として現れる名詞」として *what, it, this, things* など、「副詞的に修飾する語」として *fully, really, how* などが抽出され、それぞれの共起頻度やスコアが表示されます。これにより、単に単語同士が一緒に出るかだけでなく、どのような文型でよく使われるかまで把握できます。

以上の KWIC、頻度、共起の基本機能を組み合わせることで、コーパスから多角的に情報を引き出すことができます。では、最後に具体的な分析例として、BNC を用いて英単語 *understand* の用

法を調べてみましょう。

## 検索例：BNC における *understand* の使用傾向

ここでは実際の研究のミニチュア版として、BNC（英国英語コーパス）における *understand* の使用傾向を分析してみます。*understand*（「理解する」）という動詞がどのような場面で使われ、どんな意味の違いがあるのかを、コーパス検索によって探ってみましょう。

まず Sketch Engine でコーパスとして BNC を選択し、検索バーに `[lemma="understand"]` と入力して検索します（lemma 指定により *understand, understands, understanding, understood* の全形態を対象にします）。結果として、BNC 全体での *understand* のヒット件数と KWIC 一覧が得られます。BNC 約 1 億語中のヒット件数はおよそ数千件程度になります。その頻度は百万語あたりで見ると数十回程度となり、*understand* は英語の中では比較的よく使われる動詞と言えます。

KWIC 一覧をざっと眺めると、*understand* が使われる文脈にはいくつかパターンがあることが分かります。まず目立つのは、一人称主語との組み合わせです。「**I understand**」で始まる文が頻出しており、例えば「I understand your point」（あなたの言いたいことは分かります）のように相手の発言や事情を受けて理解を示す用法が多く見られます。また「**I understand that** …」の形もしばしば登場します。この構文は「…であると理解しています／承知しています」という意味で、情報を得てそれを理解したことを表明するフォーマルな言い方です。例えば「I understand that Mr. Smith has resigned」（スミス氏が辞任したと伺っています）のような用例です。

次に二人称や疑問形での用例として、「**Do you understand?**」や「**Understand?**」といった形も散見されます。これは会話で相手に理解を確認したり命令的に「分かったかい？」と念押しする場面です。また否定形では「**I don’t understand**…」や「**You don’t understand**…」といった表現が目に留まります。「私には（その意味が）わかりません」「あなたは（状況を）わかっていない」といった使い方で、しばしば談話の中で自分の理解不足を認めたり、相手の誤解を指摘したりする文脈で使われます。

さらに共起分析からは、*understand* が様々な語と結びついて異なるニュアンスを生むことが見えてきます。例えば *understand* と頻繁に共起する副詞に **fully** があります。「**fully understand**」は「完全に理解する」という意味で用いられ、「I don’t fully understand」や「You must fully understand」などの形で深い理解の有無を強調しています。同様に **perfectly** も共起しており、「I understand **perfectly**」のように「十分承知しています」の意味で使われます。これらは理解の程度を修飾するパターンです。

一方、*understand* の後に続く名詞目的語にも注目すると、例えば **thing** や **problem** といった語がしばしば現れます。「I understand **one thing**」「understand the **problem**」など、理解の対象を明示する使われ方です。また目的語ではなく後続の構文として **why** や **how** などの疑問詞節が多く見られます。例えば「I can’t understand **why**…」（なぜ…か私には理解できない）、「We must understand **how**…」（どのように…か理解しなければならない）といった形です。疑問詞節を伴う場合、*understand* は「理由や方法などを把握する」という意味合いになります。このように、後続するパターンによって「事実を承知する」「趣旨を理解する」「理由を察する」など微妙に異なる

ニュアンスが現れます。

最後に、コーパスから抽出された用例を基に *understand* の語義の幅を考えてみましょう。典型的な用法はもちろん「（言葉・内容を）理解する」です。しかし「I understand you.」のような用例では「あなたの気持ちがわかる（共感する）」という文脈で使われることもあります。また、「It is understood that …」という受動構文では「…ということになっている／…と解されている」という意味で、暗黙の了解事項を述べる表現になります。このように *understand* には文脈によって「知る・分かる・解釈する・同意する」など様々な解釈が可能であることが、コーパスを調べることで具体的な例とともに確認できました。

以上の簡単な分析例からも分かるように、コーパスを使えばある語の使われ方や意味の広がりをデータに基づいて明らかにすることができます。頻度情報はその語の一般性や重要度を示し、共起語は語のネットワークや特徴的なフレーズを教えてくれます。KWIC による文脈の観察からは、語の持つニュアンスの違いや使用場面の典型例を掴むことができます。これらはすべて、従来の辞書や直感だけに頼っていたのでは得にくかった知見です。

本章では、コーパスの基礎から実践までを概観しました。コーパスは現代の人文学研究になくてはならない強力なツールです。大規模で多様な言語データを用いることで、直感や限られた例に頼った従来の研究に比べ、はるかに客観的で再現性の高い分析が可能になります。もっとも、適切なコーパス設計やノイズ対策など乗り越えるべき課題もありますが、それらについても本章で述べたポイントを踏まえれば十分に対処可能です。ぜひ本章で紹介した Sketch Engine 等のツールを実際に使ってみて、再現性ある言語研究の第一歩を踏み出してみてください。自分で手を動かしてコーパス検索を行う中で、新たな発見や疑問が生まれることでしょう。その経験こそが、デジタル時代の人文学研究における大きな財産となるはずです。