12. Text Data

Photo by Christopher Gower on Unsplash

第 12 章　テキストデータの収集・前処理・分析

12.1　研究背景：文学研究 × データサイエンス

12.1.1　ディスタント・リーディングの理論的枠組み

文学研究における「distant reading（ディスタント・リーディング）」は、2000 年に Franco Moretti によって提唱されて以来、その概念と方法論の両面で多くの変遷を経てきました (Moretti, 2000)。Moretti は従来の精読（close reading）偏重の文学研究に異議を唱え、極端に少数の作品だけを尊重する精読を「神学的」とまで評しました。そして彼は「テキストの読み方は既に知っているのだから、今度はテキストを読まない方法を学ぼう」と挑発的に呼びかけたのです。

Moretti がこのように精読を批判した背景には、従来の文学研究がごく限られた正典（カノン）の作品群に依拠しすぎているという問題意識がありました (Moretti, 2000)。実際、彼によれば研究対象となる西洋文学作品は出版されたもの全体の「1%にも満たない」範囲に偏っており、例えば 19 世紀英国小説だけでも 3 万作以上が存在するのに、その大半は誰にも読まれないままだと指摘しています。Moretti はこのような「未読の巨大な作品群（the great unread）」を視野に入れるには、個々の作品を読む伝統的方法では不可能だと考えました。ゆえに、「もっと読む」こと自体は望ましいものの解決策にはならないとして、文学研究のスケールを根本的に拡張する新たな方法が必要だと主張したのです。

こうした問題意識から、Moretti は世界文学を統計的・地理的・社会的に捉える実験的な研究を次々と展開しました。その代表例が『Graphs, Maps, Trees』（2005 年）であり、文学テキストの大規模なパターンを可視化するためにグラフ（統計図表）、地図、樹形図といった手法を駆使しています (Moretti and Piazza, 2005)。実際、Moretti の一連の論考では進化論的な系統樹による小説のジャンル変遷の図示、世界システム論に基づく文学空間の地図化、登場人物同士の関係をネットワーク図で表現する試みなど、新しい「読まない読み」の具体例が提示されました。これらのアプローチは、個々のテキストに密着した精読では見いだせない大きな歴史的傾向や構造を浮かび上がらせ、ディスタント・リーディングの可能性を示すものとなりました。

Moretti の提唱したディスタント・リーディングは当初、文学研究者の間で論争を招きました。アメリカの文学研究は伝統的に精読を重んじてきたため、この「テキストを読まない」という発想は異端に映ったのです。しかしその後、Moretti がスタンフォード大学で創設に関わったスタンフォード文学ラボ（Stanford Literary Lab）などを拠点に、大規模テキスト解析による文学研究の実践が進められました。スタンフォード文学ラボからは最初のパンフレットとして Sarah Allison *et al.* による「Quantitative Formalism: An Experiment」（2011 年）が刊行され、計量的手法で文学

様式を分析する試みが報告されています (Allison et al., 2011)。こうした取り組みにより、ディスタント・リーディングは大規模コーパス分析に基づく文学研究（いわゆる計量文学研究）の代名詞ともなり、デジタル人文学時代の新たなパラダイムとして定着しました。

もっとも、Moretti が提示した「遠くから読む」というアプローチ自体は、それ以前から萌芽的な形で存在していたとも指摘されています。Ted Underwood は、Moretti が用語を創案するより前から類似の批評的アプローチは既にあり、単に名称を付けたことが新手法の発明と同義ではないと述べています (Underwood, 2019)。実際、文学史と社会科学の境界領域で先駆的研究を行った例として、Raymond Williams（20 世紀中頃）(Williams, 1958, 1973) や Radway（1984 年の『読みのロマンス』）(Radway, 1984) のような研究者が挙げられます。Janice Radway は読者コミュニティへの民族誌的調査を通じて大衆小説の受容を分析し、テクストと社会的文脈を結びつける試みを行いました。Underwood によれば、ディスタント・リーディングとは本来、デジタル技術に限らずこのように実験的・経験的な探究を人文学に取り入れることだと位置付けられます (Underwood, 2019)。こうした歴史的背景を踏まえると、Moretti 以降のディスタント・リーディングの台頭は、従来からの文芸批評の延長線上にある発展とも言えるでしょう。

ディスタント・リーディングの方法論は他の研究者にも発展させられました。例えば Matthew Jockers は、自身の 2013 年の著書『Macroanalysis』において「マクロ分析」という概念を提唱し、経済学のミクロ・マクロになぞらえて文学研究における巨視的分析を位置づけました (Jockers, 2013)。Jockers は、個別のテキストを精査するミクロな読解（精読）に対し、何百ものテキストを数量的に俯瞰するマクロ分析を導入することで、文学全体像の理解が深まると論じています。重要なのは、マクロ的な分析とミクロ的な解釈は対立するのではなく相補的であるという点です。Jockers は、人文学における伝統的な解釈も依然不可欠だとしつつ、大規模データからしか得られない知見（例えば人間の読解では見過ごしがちなごく頻出する機能語の使用パターンなど）が存在することを示しました。このようにディスタント・リーディングは、ミクロな精読とマクロな分析を組み合わせることで、文学テキストに関する新たな理解をもたらすことを目指しているのです。

こうした理論的・方法論的展開を経て、2010 年代後半にはディスタント・リーディングに基づく本格的な研究書も相次いで出版されました。例えば、Andrew Piper の『Enumerations: Data and Literary Study』（2018 年）(Piper, 2018) や Ted Underwood の『Distant Horizons: Digital Evidence and Literary Change』（2019 年）(Underwood, 2019) は、大規模データ解析により文学史の新たな像を提示する試みとして注目されました。Underwood は「ごく長期的な変化の弧（arc）は、そのスケールの大きさゆえに我々には隠れてきた——ちょうど一人の人間の目には地平線の曲率が捉えられないのと同じだ」という比喩で、大規模分析がもたらす視野の拡張を説明しています (Underwood, 2019)。個々の読者の記憶に依存した議論では捉えられないパターンも、計量的な遠隔読解によってはじめて可視化されうるという主張は、ディスタント・リーディングの理念を端的に示すものと言えるでしょう。

12.1.2　ディスタント・リーディングの方法論と自然言語処理（NLP）との接続

ディスタント・リーディングを支える方法論は、大量のテキストを対象とする分析技術に基づいています。一般に「大規模コーパス（corpus）」とは、一人の研究者が 1 年間では読み切れないほど多数のテキスト集合を指すと定義されており (Primorac et al., 2023)、このような大規模データを扱うには計算機による処理が不可欠です。ディスタント・リーディングでは、デジタル化された文学テキストのコーパス全体に対してアルゴリズムを用いてパターンを抽出し、語彙や文体、主題の分布を数量的に把握することで、個別の読書では見落とされる傾向を明らかにしようとします。

まず重要なのは、文学理論上の概念を数値分析可能な形に翻訳する「操作化（Operationalizing）」のプロセスです。Moretti はこの操作化こそが計算批評（computational criticism）の核心であると述べており、「概念から測定へ、そして現実世界へ橋を架けること」を意味すると説明しています (Moretti, 2013)。文学理論上の抽象概念（例えばジャンルや文体、プロットなど）を定量化するために、具体的な指標やアルゴリズム手順に落とし込む作業が求められるのです。この操作化によって初めて、計算機はテキスト内の特徴を数え上げ、人間には扱いきれない規模で比較分析することが可能になります。

具体的な分析手法としては、まずテキスト中の単語やフレーズの出現頻度を数える単純な統計から始まり、スタイロメトリー（文体計量）と呼ばれる手法に発展しました。例えば John Burrows による古典的研究では、英語テキスト中で最も頻出する「the」や「of」といった機能語の使用比率に著者ごとの顕著な差異があることが示されました (Burrows, 1987)。人間の読解ではあまりに当たり前すぎて無視されがちなこれら超頻出語にも文体上の意味があると証明したもので、ディスタント・リーディングはそのようなミクロな言語特徴を巨視的に捉えることで新たな知見をもたらします。この手法は作者識別や時代ごとの文体変化の分析にも応用され、計量的アプローチが文学研究に貢献しうることを早くから示しました。

例えばトピック・モデル分析（Topic Modeling）は、ディスタント・リーディングで広く用いられる自然言語処理技術の一つです。これは大量の文書に潜在するトピック（話題）を、単語の出現パターンに基づいて自動抽出する手法で、テキスト集合から主題の傾向を可視化します (Blei et al., 2003; Blei, 2012)。しかし、Lisa Rhody が指摘するように、アルゴリズムに任せきりでトピック・モデルを適用すると統計的な情報が平板に羅列されるだけで、既存のカテゴリを覆すような洞察には繋がりにくいとも言われます (Rhody, 2012)。この指摘は、アルゴリズムによる分析結果を鵜呑みにせず人文的な観点から問い直す重要性を示しており、ディスタント・リーディングにおいても結果の解釈には批評的まなざしが不可欠であることを示唆しています。

また、感情分析（sentiment analysis）によって作品のポジティブ/ネガティブな語調の変遷を捉えたり、固有表現抽出によって小説中に登場する人物・地名の網羅的抽出を行ったりする研究も行われています (Pang and Lee, 2008)。登場人物間の関係性については、ネットワーク分析を用いて小説内の人物相関図を自動生成する試みもあります (Elson et al., 2010; Moretti, 2011)。さらに機械学習によるテキスト分類も有力な手法です。ジャンルや時代の自動判別モデルを訓練すれば、特定の特徴に基づいて作品がどのジャンル・時期に近いかを定量的に評価できます。実際、Underwood

は数千冊規模のコーパスに対しロジスティック回帰モデルを適用し、小説（フィクション）と言語的特徴が似たノンフィクション作品を判別することで、小説文体の歴史的変化を定量的に測定しています (Underwood, 2019)。その結果、19 世紀から現代にかけて小説は伝記などのノンフィクションとは異なる方向に発展し、フィクションは動作動詞や身体部位に関する語が増加していったのに対し、ノンフィクションでは政治や信念といった抽象的語彙が多く使われ続けるという対照的な傾向が明らかになりました。

ディスタント・リーディングの研究では、近年「仮説検証型」のアプローチが重視されるようになっています (Underwood, 2019)。単にデータから興味深いパターンを探すだけでは、都合の良い例をつまみ食いしてしまう（いわゆるチェリーピッキング）危険があるためです。その対策として、まず人文学的な問題関心に基づいて仮説を立て、それを検証するために統計モデルを構築するという手順が推奨されます。例えばスタンフォード文学ラボの研究者らは「小説は歴史的に『語る (telling)』から『見せる (showing)』への傾向変化があるのか」という仮説を検証するため、1800 年から 2000 年に書かれた小説コーパスの分析を行いました (Heuser and Le-Khac, 2012)。その結果、Ryan Heuser と Long Le-Khac は小説の中で身体描写のための形容詞が着実に増加し、抽象名詞が減少するという言語的変化を報告しています。

一見するとこの結果は「語りから描写へ」の発展を裏付けるようですが、Underwood は更に比較対象として伝記作品のコーパスを分析に加えました (Underwood, 2019)。その統計モデルによれば、フィクションとノンフィクション（伝記）は時代とともに言語使用が乖離していき、結果として小説は即物的な描写にますます特化していったことが示されています。このように、仮説主導で分析を設計し結果を吟味する姿勢によって、計量分析から得られたパターンに文学的な解釈を与え、トリヴィアルな相関ではない意味のある知見へと高める努力がなされています。

近年ではさらに高度な自然言語処理技術の発展により、ディスタント・リーディングの手法も洗練されつつあります。たとえば Transformer を基盤とした言語モデル（BERT や GPT-4、GPT-5 など）が登場し、テキストの意味や文脈をより精細に捉えた分析が可能になりました。これら最新の NLP モデルは、人間に近い流暢さで文章を生成したり、文体模倣を行う能力を備えており、その応用として大規模コーパスから物語構造や文体上の特徴を抽出する研究も技術的には可能になってきています。ただし、モデルが高度化する一方で、その結果に対する解釈や評価はなお人文学者の判断に委ねられる部分が大きく、アルゴリズムが示すパターンを人間の文脈知と照合する作業は欠かせません。先端技術の導入によってディスタント・リーディングの精度は向上していますが、それでもなお「読むこと」の意味や文学的意義を問い直しつつ活用する姿勢が重要だといえます。

なお、当初 Moretti がディスタント・リーディングで狙ったのは文学史全体のマクロな構造把握でしたが、その後この手法の適用範囲は拡大しつつあります。Katherine Bode は、近年のディスタント・リーディング研究では必ずしも大きな歴史的システムだけでなく、人物描写やプロット、劇形式といった文学研究の概念そのものを分析対象とすることが増えていると指摘します (Bode, 2018)。実際、ディスタント・リーディングは巨大なコーパス上でジャンルや制度といったマクロな現象を扱うだけでなく、小説内の「登場人物」や「物語構造」といったミクロな要素についても計量的手法で解明を試みるようになっています。言い換えれば、ディスタント・リーディングは人

文学の伝統的関心事にも接続しつつあり、定量的手法によって従来の文学概念を新たな角度から照射する段階に入っているのです。

12.1.3　ディスタント・リーディングを巡る批判と議論の動向

ディスタント・リーディングの台頭は、従来の文学研究者から様々な反響を呼び起こしました。当初、Moretti の挑発的な主張は論争の的となり、精読を重視する批評家からは反発も招きました。「読まない読み」は文学解釈の本質を損なうのではないかとの懸念も表明されました。しかし一方で、その大胆な視点は文学研究に新たな可能性を感じさせ、多くの議論を刺激する契機ともなりました。ディスタント・リーディングは支持者と批判者の間で論戦を巻き起こしつつ発展していったのです。

批判の一つは、「読まない読み」は本当に「読む」ことと言えるのか、という根源的な問いです。Drucker は 2017 年の論考「Why Distant Reading Isn't」において、コンピュータによるテキスト処理は人間の読む行為とは本質的に異なると指摘しました (Drucker, 2017)。Drucker によれば、アルゴリズムによる処理 (processing) は「字義通りで自動的・反復的」なのに対し、人間の読解 (reading) は「観念的で解釈的・生産的」な行為であり、両者は目的も性質も異なると言います。機械的なパターン抽出はあくまで手段に過ぎず、文学の意味を汲み取る「読む」営為とは別物だという批判で、ディスタント・リーディングというメタファー自体を再考すべきだという主張です。

また、ディスタント・リーディングの成果そのものが「自明のことしか示していないのではないか」という批判もあります。Moretti 自身、初期の試みの一つである「世界文学の試論」（2000 年）という論考で、推理小説の歴史を進化論になぞらえて分析しましたが、その結論は「結局、正典的な手がかり（clue）が欠如している非正典的小説は生き残れない」という、言ってみれば当たり前の帰結に落ち着きました (Moretti, 2000)。Moretti はこの結果を「真ではあるが陳腐だ」と認めています。このように、大規模分析によっても結局は予想の範囲を出ない知見しか得られないのではないか、と懐疑的な見方をする研究者もいました。

ディスタント・リーディングに対する最大級の批判として、2019 年に発表された Nan Z. Da による論説「The Computational Case against Computational Literary Studies」が挙げられます (Da, 2019)。ダーは計量的な文学研究（Computational Literary Studies, CLS）を徹底的に検証し、その多くが文学的に有意味な成果を上げておらず、統計的手法の使い方にも問題があると指摘しました。彼女は、デジタル人文学のこの分野が「質の低い文学批評」を生み出しがちであり、その発見は「陳腐であるか、もし興味深いものであっても統計的な裏付けに乏しい」と断じています。精緻な文学批評を行おうとすれば統計分析の本来の目的から逸脱せざるを得ず、逆に統計の厳密さを保てば文学の豊かな意味を極端に削ぎ落とすことになるという構造的ジレンマをダーは指摘しました。要するに、文学テキストの数が少なく意味が複雑すぎて、有意義なパターンを引き出すには無理があるというのです。

Da はまた、計算的テキスト分析の不正確さにも着目します。機械による言語解析はしばしば誤差を含み、その許容範囲はコーパスの大きさや目的次第だが、文学研究の規模では精度の低さを正当化できないと述べています (Da, 2019)。実際、SNS 解析や医療・法務文書の分析のように膨大な

データがある領域ではテキストマイニングが有効でも、文学のコーパスは比較的小規模で異質性も高いため、統計モデルの不確かさが結果を大きく左右しかねません。そのため、分析から得られるパターンは、アルゴリズム上の選択や前提に大きく依存しており、手法に些細な変更を加えるだけで結論が揺らいでしまうと Da は批判します。統計モデルの結果に深い解釈を与えようとすると、本来の適用範囲を逸脱した無理な読み替えが行われてしまい、逆に厳密な分析に徹すれば文学的には意味の乏しい結果しか得られない——Da はこのような計量文学研究のジレンマを指摘したのです。

さらに Da は、CLS の研究者たちが自らの成果を正当化するためのレトリックにも疑問を呈しました (Da, 2019)。彼女によれば、定量的な分析から明確な知見が得られない場合、研究者たちは「これは探索的な試みであり更なる研究が必要だ」といった言い回しで結果の曖昧さを弁護しがちだといいます。あるいは、計量分析の成果を伝統的な文学批評の概念になぞらえて「遠隔読解で得たパターンも従来の批評と地続きの発見である」と位置付け、自らのアプローチを擁護する傾向があるとも批判しました。Da に言わせれば、こうしたレトリックによって計量的アプローチの弱点が覆い隠されており、分野全体が自己批判なく継続してしまっているというのです。

Da の批判は計量文学研究コミュニティからも大きな反響を呼び、多くの応答や反論が寄せられました。計量的手法を擁護する研究者たちは、Da の指摘にもかかわらず適切な手法を用いれば有意義な成果が得られると反論しています。例えば Ted Underwood は、著書『Distant Horizons』（2019 年）で示した大規模分析の成果が文学研究に新たな知見をもたらすことを強調し、この種の定量研究は十分に価値があると述べました (Underwood, 2019)。実際、Underwood の著作は「量的アプローチでは有益な知識は得られない」という批判に答えるべく書かれており、各章で既存の文学史研究に一石を投じる発見を提示しています。Andrew Piper も、計量的手法が文学研究に貢献しうるという立場を採っています (Piper, 2018)。このように支持派は、統計モデルの適切な設計や人文学的解釈との組み合わせ次第で、ディスタント・リーディングは従来の批評では見出せなかった洞察を提供できると主張しています。

現在では、ディスタント・リーディングは伝統的な精読と対立するものではなく、補完し合う関係にあるという見方が広がっています。Jockers が述べたように、マクロな分析によって得られた知見はミクロな読解によるテクストの理解と響き合い、双方を統合することでより豊かな解釈が可能となります (Jockers, 2013)。実際、多くの研究者が遠隔読解の結果を踏まえて個々の作品の再読（close reading）を行い、データで見えたパターンの具体的な意味を作品内から読み解くという往復運動を重視するようになっています。ディスタント・リーディングと精読の併用、いわば「中間距離の読解」へと向かう動きもあり、二者を統合したスケーラブルな読解戦略が模索されています。

こうした議論を経て、ディスタント・リーディングはデジタル時代の文学研究の一手法として定着したと言えるでしょう。かつては「デジタル人文学の流行の最先端」とみなされていた遠隔読解も、現在では新奇なトレンドというより標準的な手法の一つとなりました。むしろ激しい論争を経たことで、このアプローチの長所と限界が明確化され、研究者はより慎重かつ洗練された形で計量的分析を活用するようになっています。ディスタント・リーディングは文学研究に新たな視座を提供し続けていますが、それは決して人間による解釈を不要にするものではなく、むしろデータとい

う異なる視点を加えることで文学を多角的に理解しようとする試みです。最終的には、人文学的な問いと計算技術とが対話しながら、文学研究の地平を拡張していくことが、ディスタント・リーディングを巡る議論が目指す到達点なのでしょう。

12.2 テキストデータの収集

ディスタント・リーディングを実践する第一歩は、分析対象となるテキストデータの大規模な収集です。従来の文学研究では数作品の精読で十分でしたが、ディスタント・リーディングでは何百・何千もの作品テキストを揃える必要があります。例えば 19 世紀英語文学の動向を数量的に捉えたい場合、ヴィクトリア朝時代に出版された小説を網羅的に集めたコーパスを用意しなくてはなりません。Moretti が提起した「読まれざる膨大な作品群（the great unread）」を視野に入れるには、それらをデータとして収集することが不可欠なのです。幸い 19 世紀の英文学作品は著作権が失効しているものが多く、テキストデータは比較的入手しやすい状況にあります。とはいえ、どのような範囲・規模の作品を集めるかは研究目的に応じて慎重に計画する必要があります。

コーパスを構築する際には、まず対象とする時代やジャンル、作品の種類を明確に定めます。例えば「19 世紀イギリスの小説」を対象にする場合でも、範囲を 1800–1899 年とするのか、ヴィクトリア朝（1837–1901 年）に限定するのか、あるいは英国以外で英語で書かれた小説も含めるのかなど、スコープの設定次第で集める作品が変わります。また分析の目的によっては、さらに細かく条件を決めることもあります。登場人物のネットワーク分析をしたいなら長編小説が望ましいでしょうし、文体変化を追うならベストセラーからマイナー作品まで幅広く含めた方が良いでしょう。仮説主導型の研究であれば、検証したい仮説に関連する作品群を選定することになります。こうしたコーパスの設計段階から、既にリサーチクエスチョンに沿った戦略的判断が求められるのです。

具体的なテキストデータの入手源としては、インターネット上の電子テキストアーカイブが重要な役割を果たします。代表的な例として Project Gutenberg は数万点に及ぶパブリックドメインの文学作品をテキストファイルで提供しており、19 世紀英文学の主要な小説（たとえばジェーン・オースティンやチャールズ・ディケンズ、アーサー・コナン・ドイルなど）の全文データを容易に取得できます。実際、Elson らの研究ではディケンズやオースティンを含む 60 作品もの 19 世紀小説コーパスを構築しています。他にも、Internet Archive や Google Books、HathiTrust のデジタルライブラリには 19 世紀の書籍が大量にスキャン・電子化されています。ただし、こうした大規模データを直接扱うにはプログラミング知識や専門的なデータ取得手法（例えば API の利用やウェブスクレイピング）が必要になる場合もあります。また研究機関によっては独自の電子テキストコレクション（たとえばオックスフォード大学版の小説全集等）を構築していることもあります。まずは利用可能なリソースを把握し、研究目的に適ったコーパスを収集する計画を立てることが肝要です。

データ収集にあたって忘れてはならないのが、収集対象のバイアスと網羅性の問題です。簡単に手に入る電子テキストは有名作家や正典（カノン）に偏りがちであり、結果として「精読が神学的だ」と批判した Moretti 自身の指摘（ごく一部の作品に偏重している）を、ディスタント・リー

ディングでも繰り返してしまう危険があります。たとえば Project Gutenberg のラインナップは古典的名作が中心で、19 世紀に無数に書かれた大衆小説や忘れられた作品は網羅されていません。そのため、真に「遠くから読む」ことで文学全体像を捉えるには、可能な限り裾野の広い作品収集を心がける必要があります。学界の試みとして、スタンフォード大学文学ラボが構築した 19 世紀英小説の約 3000 作品コーパスや、Illinois 大学の Underwood が HathiTrust の蔵書データを基に整備した 3700 冊以上のコーパスなどがあります。Katherine Bode はこのようなデータ駆動の文学史研究において、研究者自らが分析に用いるデータセットを批評的に構築・公開するアプローチを提唱しています。Bode によれば、大規模コーパスは単なる分析素材ではなく「文学システムの学術版（scholarly edition of a literary system）」として編纂されるべきだとされ、収集作品の選択基準やデータ化の過程を含めて批評の一部と位置付ける必要があるのです (Bode, 2018)。

もう一つ考慮すべきポイントは、テキストデータ自体の質と、その周辺情報（メタデータ）です。特に過去の作品を扱う場合、電子化のプロセスで生じるノイズや欠損に注意しなければなりません。例えば 19 世紀の書籍はしばしばスキャン画像から OCR（光学文字認識）でテキスト化されていますが、その認識精度は必ずしも高くありません。印刷の擦れや古い活字の字体の違いにより、文字化けが発生したり、単語が抜け落ちたりといった誤りが含まれることがあります。このような OCR 誤認由来のエラーは、収集段階では見逃されがちですが、分析結果に影響を与える可能性があります。Nan Z. Da も批判的論考の中で、計算機による言語解析には誤差がつきものだと指摘し、文学研究レベルの比較的小規模なコーパスではその誤差を無視できないと述べています（彼女は計量文学研究の多くが統計的に不安定で再現性に欠けると論じました）(Da, 2019)。したがってデータ収集の段階から、テキストの正確さや抜け漏れの有無を点検し、必要に応じて底本（オリジナルの書籍）や複数の版を突き合わせてテキストを校正することも求められます。

さらに、集めたテキストに付随するメタデータ（書誌情報）もできるだけ確保しておきたいところです。作品名、著者、出版年、ジャンル、初出版媒体（雑誌か単行本か）といった情報は、分析結果を解釈する上で極めて有用です。例えば語彙の変化を年代順に追うには各作品の出版年が不可欠ですし、文体の特徴を作家ごとに比較するには著者名ラベルが要ります。また小説とノンフィクションの差異を分析するにはジャンル区分が必要でしょう。Underwood の研究のように、小説コーパスと言語的に似た伝記や書簡といったノンフィクションを比較対象に加えることで、フィクション特有の変化を際立たせることも可能です (Underwood, 2019)。そのため収集段階で各テキストのメタデータを整理し、分析に使いやすい形で保存しておくことが重要です。昨今では電子図書館のデータに MARC レコード（書誌データ）が付属している場合もあり、それらを解析して自動的にメタデータを取得することもできます。ただし古い作品ほど情報が不足していたり誤っていたりすることもあるため、人手による確認が求められる場面も出てきます。

最後に留意すべきは、データ収集のグローバルな偏りです。Primorac (2023) は、ディスタント・リーディングの前提として各国の文学アーカイブのデジタル化状況が極めて不均等である点を指摘しています (Primorac et al., 2023)。英語圏の 19 世紀文学などは大規模に電子化されていますが、非英語圏や周縁地域の文学作品は未だデジタル化が進んでいないケースも多々あります。このことは、世界文学を比較するような研究では特に問題となります。データが存在しない領域について

は、それを単に「作品が存在しない」かのように誤解してはならず、単に「データが欠如している」こととして扱うべきだと Primorac は警鐘を鳴らしています。したがって収集フェーズでは、自身の構築するコーパスが持つ言語的・地理的バイアスにも自覚的である必要があります。研究目的によっては多言語コーパスを構築したり、あるいは一つの文化圏内に絞ったりと方針はいろいろですが、少なくとも「手に入るデータだけで代表性を安易に主張しない」という慎重さが求められるでしょう。こうした配慮を込めつつ、ディスタント・リーディングの土台となるテキストデータを可能な限り包括的かつ正確に収集することが、この段階のゴールとなります。

12.3 テキストデータの前処理

大量のテキストデータを収集した後は、それらを分析に適した形に整える「前処理（プリプロセッシング）」の工程が待っています。生のテキストデータは往々にしてそのままでは計算機による分析に適しません。不要なノイズを含んでいたり、形式が統一されていなかったり、人間にとっては意味があっても機械的処理には向かない構造を持っていたりするためです。前処理とは一言で言えば、テキストから分析に不要な要素を取り除き、扱いやすいデータ形式に変換するプロセスです。この工程は地味に思えるかもしれませんが、分析結果の信頼性を左右する重要なステップでもあります。前処理を丁寧に行うことで、後続の分析段階でアルゴリズムが本来注目すべきパターンを正確に捉えられるようになりますし、逆に前処理が不十分だと誤ったパターンやノイズに分析が引きずられてしまう可能性があります。

まず取り組むべきはテキストデータから明らかに分析対象外となる部分を除去することです。例えば、電子化された小説テキストには序文や注釈、校訂者による解説、さらには Project Gutenberg の場合は冒頭や末尾にライセンス情報やスキャン提供者メモが含まれていることがあります。文学研究の分析では普通それらは不要ですから、自動的に検出して削除するスクリプトを書くか、規則に従ってトリミングする必要があります。書籍によっては章題やページ番号、欄外の見出し語などが本文中に紛れていることもありますので、それらも取り除きます。特に OCR で生成されたテキストの場合、改行や段組みの痕跡が不自然な位置で挿入されていることがあるため、一旦すべての改行をスペースに置換してから段落単位で再構築するといった処理も有効です。要するに、テキストデータを「作品本文のみ」の綺麗なシーケンスに整形することが初歩的ながら重要な作業となります。

次に、テキスト内の文字・表記の統一を図ります。19 世紀のテキストでは表記ゆれが現代以上に多様です。綴り字が時代や作家によって異なる（例: “showed” と “shewed”）場合や、大文字小文字の使い方、句読点の打ち方なども揺れがあります。分析目的によってはこれらを正規化（ノーマライズ）することが望ましいでしょう。例えば単語頻度を数える場合、大文字と小文字の違いは区別しない方が語数計測の精度が上がります。そのためテキストをすべて小文字化（lowercasing）する処理は基本的によく行われます。ただし、人名や地名などの固有名詞も小文字化されてしまう点には注意が必要です。また、古いテキストでは句読点や引用符が現在と異なる記号で表されていることもあります（例: ダッシュ記号 “–” や古い綴りのアクセント記号付き文字など）。こうした

特殊文字を一律に標準的な記号に置換することで、後段の解析プログラムがそれらを正しく認識できるようにします。もし複数のソースから集めたテキストを併用する場合は、ハイフンの有無やスペルの違い（例えば「coordinate」と「co-ordinate」のような差異）なども統一することを検討します。ただし、スペルの歴史的変化自体を分析したい場合は話が逆で、むしろ正規化せずにオリジナルのまま残す方がよいでしょう。このあたりの判断も、研究の問いに即して行う必要があります。

英語テキストの前処理では、単語への分割（トークン化）も不可欠なステップです。人間は文章を読んで自然に単語を認識できますが、計算機は空白や句読点を手がかりにして単語境界を判断します。英語の場合は基本的に空白で区切れば単語列が得られますが、実際には “Mr.” や “don’t” のようにピリオドやアポストロフィを含むものや、ハイフンつきの複合語（“six-pack” など）、引用符や括弧に挟まれた語など、細かなケースがあります。前処理段階では、こうしたケースを適切に処理して単語単位のリスト（トークン列）を取得します。多くの場合、句読点は除去し、記号も分析には使わないので削除します（感嘆符や疑問符の頻度を分析したいといった場合は別ですが）。また数字も普通はテキストの内容分析からは外すため 0-9 の数字をすべて 0 に置換するか削除することが多いです。これらの操作により、テキストは「単語の並び」という極めて単純な情報列に変換されます。この単語リスト（もしくは単語のベクトル表現）こそが、計量的なテキスト分析の出発点となります。

トークン化した単語リストに対しては、必要に応じてさらに処理を加えます。例えば頻度分析やトピックモデルなどでは、あまりにも出現頻度の高い単語は分析上のノイズになることがあります。英語では “the”, “of”, “and” などの超頻出語（いわゆるストップワード）は文書間の差異を生みにくいため、場合によっては除去します。ただしスタイロメトリーの文脈では、逆にそれら超頻出の機能語こそが文体の特徴を担うと考えられます。Burrows の先駆的研究以来、英文学の著者識別では「the」「of」などの機能語の比率が重視されてきました。したがって分析目的が文体比較や作者推定である場合、ストップワードは除去せずむしろ主たる分析対象とします。一方、作品の主題的傾向を知るにはストップワードを外し、意味を持つ単語（名詞・動詞・形容詞など）の出現パターンを見る方が有効です。このように、どの単語を分析に用いるか（あるいは無視するか）の選択も、研究の問いに合わせて決める必要があります。また類似した単語形（例えば動詞の活用形や名詞の単数・複数形など）をひとまとめに扱いたい場合は、ステミングやレンマ化といった処理を行います。ステミングは語尾変化を切り落として語幹（stem）を抽出する簡易的な方法で、例えば “walking”,“walks”,“walked” をすべて “walk” に変換するといったルールに基づきます。一方レンマ化は辞書的な原形（lemma）への変換で、動詞なら原形、名詞なら単数形に統一する処理です。これらの処理を行うことで、同一単語の異形が別々に数えられるのを防ぎ、概念レベルでの頻度把握が容易になります。ただし文体のように表層の違い自体に意味がある分析ではステミングは逆効果ですから、やはり使い分けが重要です。

前処理には他にも様々な工夫が考えられます。例えば小説の登場人物ネットワークを解析したいなら、人名をテキストから全て抽出する必要があります。しかし一般のテキストから固有名詞を漏れなく取り出すのは簡単ではありません。大文字で始まる単語を拾うだけでは不十分で（文頭の単語や “I” もヒットしてしまう）、文脈を見て固有名詞を判定したり名前の異形（フルネームと

ファーストネームだけの表記など）を統合したりする処理が求められます。近年は自然言語処理の技術である固有表現抽出（Named Entity Recognition, NER）を使って、自動的に人物名や地名をタグ付けすることも可能になっています。ただし文学テキストの場合、架空の人名やあだ名、古風な地名なども含まれるため、市販の NER モデルでは見落としも起こりえます。Elson らの研究では、19 世紀小説から登場人物同士の対話関係を抽出するために、まず文中の発話（引用符で囲まれた部分）を検出し、それが誰の発言かを自動で帰属させるアルゴリズムを開発しています。このように、分析したいターゲット（人物関係など）に合わせてテキストに特殊な前処理を施すことも、ディスタント・リーディングの実践では求められます。

テキスト前処理の最終段階として、分析手法が直接扱えるデータ形式への変換があります。多くの計量テキスト分析では、文書ごとの単語頻度表（ドキュメント-ターム行列）や、単語の出現リストを使います。トピックモデルであれば各文書内の各単語の出現回数が入力となりますし、スタイロメトリーであれば各テキストの単語頻度分布同士を比較します。また時系列の分析では年代ごとに集計した単語頻度の推移を見ることもあります。近年の深層学習モデルでは文章をベクトル（数値列）に変換して扱いますが、その場合も前処理で適切なベクトル化（ベクトライゼーション）が行われます。いずれにせよ、人間が読むための文字列を、一旦は機械学習や統計解析の入力に適した数値データや構造化データに変換するのがこの段階の目標です。Bode が述べるように、テキストコーパスを構築・前処理する過程には編集者（研究者）の判断や介入が多分に含まれます。そのため、どう前処理したか（例えばどの単語を除去したか、どう正規化したか）を記録し公開することが、研究の再現性のためにも望ましいとされています。以上のように多岐にわたる前処理を経て、ようやくテキストは分析の準備が整います。

12.4 テキストデータの分析

十分な規模のテキストデータを収集し、それをクリーンな形に前処理できたら、いよいよディスタント・リーディングの核心である「分析」の段階に入ります。分析手法は研究の問いに応じてさまざまですが、いずれも大量のテキストから人間の読みでは見つけられないようなパターンを抽出し、それを文学的知見へと結びつけることを目指す点で共通しています。本節では、文学研究で実際によく使われる分析アプローチを具体例とともに紹介しつつ、得られた結果をどのように解釈し議論に繋げるかについて述べます。対象は引き続き 19 世紀英文学コーパスと想定し、その中から浮かび上がる言語パターンを検討する流れを追ってみましょう。

分析の入口として、まずは基本的な記述統計にあたる単語頻度や語彙の多様性を見ることが考えられます。例えばコーパス全体で最も頻出する単語は何か、各作品ごとに特徴的な単語はあるか、語彙の豊富さ（タイプ数/トークン数の比率や平均文長など）はどうか、といった指標は、大まかに文体や内容の傾向を掴む手がかりになります。19 世紀英国小説の典型として、やはり “the”, “and”, “of” といった文法的機能語が上位を占めるでしょうが、これは単に英語という言語の特性ですので大きな発見ではありません。しかし、例えば頻出順上位 100 語のリストを小説とノンフィクション（伝記や手紙など）で比較すると、違いが見えてきます。Ted Underwood の分析によれ

ば、19 世紀において小説の語彙は徐々にノンフィクションから乖離していき、特に 1850 年以降になると小説を特徴付ける語として人称代名詞や対話を示す動詞（例: “said” 等）が顕著に多くなるのに対し、ノンフィクションでは依然として “is”, “also” など説明的・抽象的な語が多いことが確認されています。この結果は、小説というジャンルが発展するにつれ、より人物描写や会話主体の語彙にシフトし、一方でノンフィクションは情報提示的な文体に留まった可能性を示唆します。まずはこのように、頻出語の分布という基本的な統計からジャンル間・時代間の違いを捉え、研究の仮説づくりに役立てることができます。

文体分析（スタイロメトリー）の手法を用いれば、より精緻に作家や作品間の文体上の距離を測ることが可能です。Burrows 以来の伝統的な方法は、超頻出語の出現比率を各テキストについて算出し、それらを多変量解析にかけて文体の類似・相違を明らかにするというものです。具体的には、例えば 19 世紀の主要な小説家（オースティン、ディケンズ、トーマス･ハーディ等）の作品をすべてコーパスに入れ、各作品における “the”, “of”, “and”, … といった上位 n 語（典型的には 50〜200 語）の割合を計算します。次に、それら割合のプロフィールに基づいて作品間の距離を測り、主成分分析（PCA）やクラスター分析で可視化します。すると、驚くべきことに作者ごとに作品がまとまってクラスターを形成したり、年代順に変化する軌跡が見えたりします。これは、人間の読む印象では捉えにくい文体上の特徴が、機械的な頻度プロファイルによって浮かび上がる好例です。Jockers は著書『Macroanalysis』において、このような計量文体分析を何百ものテキストに拡張し、作家や時代ごとの文体的距離をマッピングしています (Jockers, 2013)。この手法で得られた作家間の距離は、文学史上の影響関係や流派の違いと対応する場合もあり、文体という観点から文学史を再評価する材料となります。ただし、クラスターの解釈には注意が必要です。単に似ている／異なると示されるだけでは何が文体上の差異なのか不明なため、頻度寄与の高い単語を調べ「ある作家は対話文中の “I” や “you” が多いが、別の作家は地の文での冠詞 “the” の多用が特徴になる」といった具体的な特徴に落とし込む作業が求められます。スタイロメトリー分析は作者の判別だけでなく、未知の著者の文章を既知のスタイルとの近さから推定する作者推定（アトリビューション）にも用いられており、計量的手法が文学上の長年の謎（例えば匿名で発表された作品の真の作者）に寄与する場面も出てきています。

トピック・モデル分析も、ディスタント・リーディングで広く使われる強力なツールです。Blei らによって提唱された潜在的ディリクレ配分（LDA）に代表されるトピックモデル手法では、コーパス内の単語の共起パターンから、文書集合に潜む「トピック」を自動推定します (Blei et al., 2003; Blei, 2012)。例えば 19 世紀小説 3000 冊に LDA を適用すると、「産業革命の経済活動に関するトピック」「恋愛や結婚に関するトピック」「植民地や異国が舞台の冒険に関するトピック」など、コーパス内で頻繁に一緒に現れる単語の集合が抽出されるでしょう。それぞれのトピックは確率分布として表現され、各文書がどのトピックをどの程度含んでいるかも算出できます。この結果を使えば、年代ごとの主要なトピックの変遷を分析したり、作家ごとの関心の違いを定量的に比較したりできます。実際、先述した Heuser と Le-Khac の研究ではコーパス全体の語彙変化をまず相関分析で見出し、それを確認するためにトピックモデルを用いて同様の傾向が出現するか検証しています。その結果、「抽象的価値語」と「具体的描写語」の増減という劇的なトレンドが別手法で

も再現され、発見が特定の手法に依存しない実在の歴史的変化であることが裏付けられました。このようにトピックモデルは探索的にも検証的にも使える柔軟な手法ですが、一方で解釈には人文的なセンスが求められます。Lisa Rhody はトピックモデルの結果だけを眺めても既存のカテゴリーをなぞるような平板な解釈に陥りがちだと批判しており (Rhody, 2012)、モデルが吐き出すトピック語群にどのような意味づけを行うかが研究者の腕の見せ所となります。「トピック」の名称を考案し、それが文学的に妥当か吟味する過程で、初めて定量分析が批評的インサイトへと昇華されるのです。

感情分析（センチメント分析）もテキストマイニングの代表的手法で、文学作品のトーンやキャラクターの心情推定に応用されています (Pang and Lee, 2008)。例えば長編小説の各章ごとに感情語をスコアリングし、物語全体の感情曲線（プロットアーク）を描くことができます。19 世紀のゴシック小説であれば、クライマックスに向けてネガティブな語が増え恐怖の度合いが高まるといったパターンがあるかもしれません。実際に複数の小説で感情曲線を比較すれば、ジャンルごとの物語展開の特徴を数量的に述べることができます。もっとも、文学テキストの感情分析には課題もあります。現代のレビューや SNS と違い、古い文学作品では感情表現が婉曲的だったり、ポジティブな語とネガティブな語が反転した意味（皮肉や風刺）で使われたりする場合があるため、単純な極性分析が妥当しないこともあります。それでも、大量のテキストで平均を取ればノイズは相殺され、全体傾向として有意な差異が現れる場合があります。例えば Heuser たちの分析では 19 世紀小説における身体描写（ポジティブでもネガティブでもない中立的な具体描写）が増え、人格や感情を表す形容詞（しばしば評価を伴う抽象表現）が減ったという結果が示されました。これは「心情を言葉で語る」のではなく「状況を描写して示す」方に小説が舵を切ったことを意味し、感情表現の直接性が薄まったとも解釈できます。このように、感情分析は物語の雰囲気や心理描写の傾向を計量化する手段として有用ですが、その数値を文脈に即してどう読むかが重要になります。

さらに進んだ分析として、ネットワーク分析による物語構造の解明も挙げられます。先に触れた Elson らの研究は、抽出した対話情報から小説内の登場人物同士の関係ネットワークを構築しました (Elson et al., 2010)。60 作品もの 19 世紀小説を自動解析して得られたネットワーク指標を比較することで、従来は数作品の例示で語られていた文学理論を大規模に検証しています。例えば「登場人物数が多い大河小説では、一人当たりの会話量が減る（対話の密度が下がる）」とか「都会を舞台にした作品では田舎を舞台にした作品より人間関係が希薄になる」といった文学研究者の主張が、本当に一般的傾向と言えるのかを確かめたのです。結果は必ずしも既成の通念を支持しませんでした。Elson らは、対話ネットワークに関する複数の特徴量を算出して統計分析を行いましたが、その多くにおいて従来の仮説とは異なるパターンを発見しました。例えば彼らのコーパスでは、登場人物が多い作品でも一概に対話が希薄になるわけではなく、逆にある程度以上キャラクター数が増えると小集団（クリーク）間で濃密な会話圏が生まれる傾向が見られたのです。このようにネットワーク分析は、小説世界の構造（誰と誰がどの程度関わるか）を客観指標で表し、それを作品間で比較することで新たな視点を提供してくれます。Moretti も『ネットワーク理論、プロット分析』（2011 年）でシェイクスピアの戯曲に登場人物ネットワークを適用し、悲劇では主人公を中心にネットワークが星型に広がるのに対し、喜劇ではネットワークが断片化する（複数の小

さな集団に分かれる）傾向を指摘しました (Moretti, 2011)。これも一種のディスタント・リーディングによる文学形式の再発見といえ、プロット展開やジャンル特性を数量的に捉える試みとして興味深いものです。

ディスタント・リーディングの分析では、機械学習を用いたテキスト分類も強力な手法です。Underwood の近年の研究では、数千冊規模の文書集合に対し「これは小説か否か」を判別する分類モデルを学習させ、フィクションとノンフィクションの言語的差異を定量的に測定しました (Underwood, 2019)。その結果、小説とノンフィクションは時代が下るにつれて語彙選択の面で乖離が大きくなり、1900 年頃までにかなり明確に区別できるようになることが示されています。このモデルが捉えた区別の要因を調べると、小説では人物の行動や対話に関わる単語（人名や過去形の動詞、身体部位や感覚に関する語など）が多く、ノンフィクションでは抽象的な概念語や形式的な表現（例えば文中の “Mr.” や “Dr.” など敬称、論説的な語）が多いという特徴が浮かび上がりました。つまり、計算機が検出したフィクション性の指標は「この文書には人物が登場し、何らかの行動や会話が描写されているかどうか」という点に集約されたとも言えます。これは人間の直感とも通じる部分ですが、何百年にも及ぶ文書を一括で分類しその特徴量を分析することで、フィクションというジャンルが語彙面で自己定義を強めていった過程を裏付ける定量証拠が得られた意義は大きいでしょう。このようなジャンル分類や時代識別のモデルをさらに発展させれば、未知の作品がいつ書かれた小説に近いかを推定したり、作品の文体が属する流派を自動分類したりといった応用も可能になります。もっとも、機械学習モデルはその判断根拠がブラックボックスになりがちで、慎重な可視化と検証を経て初めて人文学的な解釈に耐える知見となります。Underwood 自身、モデルの重み（単語の寄与度）を詳細に分析し、それを従来の文学史と照らし合わせることで、「19 世紀以降、小説はフィクション内での身体性描写を強め、ノンフィクションとは異なる語彙世界を築いた」というストーリーを紡いでいます。このように、分類モデルの数字を出発点として、そこに潜む言語運用の変化を読み解く作業が不可欠となるのです。

大規模テキスト分析から知見を引き出す際には、常に批判的なまなざしと人文学的な仮説が必要です。前節までに述べたように、近年は単なるデータマイニングではなく仮説検証型の遠隔読解が推奨されています。つまり「データに何か面白いパターンはないか」と闇雲に探すのではなく、「この歴史的現象はテキスト上にどのように現れているか」という問いを立て、それに答えるための指標を計量分析で求めるという姿勢です。実際、スタンフォード文学ラボの研究や Underwood の近年の仕事は、既存の文学議論から発した仮説をデータで試すというデザインになっています。例えば Heuser & Le-Khac (2012) は「19 世紀小説は『語りから描写へ』シフトしたか？」という文学史上の仮説に定量的証拠を与えようとしました (Heuser and Le-Khac, 2012)。彼らは約 3000 作品の語彙変化を分析し、人格的・道徳的な抽象語が減少し、具体的・身体的な語が増加するという明確なトレンドを発見しました。さらに Underwood はその結果を受け、小説とノンフィクションの差という観点から同様の現象を確かめました (Underwood, 2019)。このように一連の分析は、単に「面白いパターンを見つけました」で終わるのでなく、「そのパターンはどの文学的疑問に答え、どの議論を前進させるのか」を意識しています。Nan Z. Da が批判したように、計量的なアプローチは注意しないと陳腐な結果か統計的に心許ない主張しか出せない恐れがあります (Da, 2019)。それ

を克服するためにも、分析の段階では結果を鵜呑みにせず、関連する別データで確かめたり、統計的有意性をテストしたり、さらには再び個別のテキストに立ち返って結果を精読的に検証することも重要です。

分析結果の解釈と従来知との接続もまた、ディスタント・リーディングの成果を有意義なものにする鍵です。いかに精密なアルゴリズムでも、それ自体が文学的意義を語ってくれるわけではありません。得られた数値や可視化されたグラフに対して、「この変化は何を意味するのか」「このクラスター分けはどんな文学史上の区分に対応するのか」を考えるのは研究者です。例えば、トピックモデルで抽出されたトピックに「産業・労働」「家庭・結婚」と名付けるのも研究者の解釈ですし、ネットワーク分析で得られた指標の差異から「この作品では主人公が孤立している」と読むのも人間の仕事です。機械が発見したパターンと人文的文脈との橋渡しをすることで、初めてディスタント・リーディングは文学研究に貢献できます。この点で、ディスタント・リーディングは決して精読（close reading）と対立するものではなく、むしろ補完的な関係にあります。多くの先行研究が強調するように、遠隔読解で得られたマクロな視点の発見は、再びミクロな精読にフィードバックされるべきです。Andrew Piper も、計量的手法で全体傾向を掴んだ後に、具体的作品へと「ドリルダウン」して個別分析を行う重要性を説いています (Piper, 2018)。ディスタント・リーディングと伝統的読解を行き来する「中間距離の読解」によってこそ、データから得られた知見が文学的意味を帯びたものとなるでしょう。

以上、文学研究とデータサイエンスを巡る学際的な研究分野の動向から、テキストデータの収集・前処理・分析に至る一連の手法と考え方を概説しました。19 世紀英文学を例に挙げながら説明しましたが、これらのプロセスと手法は他の時代・言語の文学研究にも広く応用可能です。重要なのは、研究目的に応じて適切なデータセットを構築し（収集）、それを信頼できる形に磨き上げ（前処理）、さらに有効な手法で問いに答えるパターンを引き出す（分析）という一連の流れを一貫して批評的視座からコントロールすることです。ディスタント・リーディングは単なるデータ処理ではなく、「データに基づいて遠くまで読む」行為です。人間の読む行為と計算機のパターン認識を往復させることにより、文学テキストに潜む新たな地平が開けてきます。テキストデータの収集・前処理・分析というプロセスの積み重ねの先に、従来の文学研究では見えなかった景色が立ち現れる——それが現代の文学研究におけるディスタント・リーディングの醍醐味と言えるでしょう。